

项目经历

姓名：【待补】 | 联系方式：【待补】 | 目标岗位：【待补】 | 本页仅含项目经历

项目经历

晶圆 BIN 图缺陷判读与中文描述 · 视觉语言模型（公开数据个人项目）

2026.09 - 2026.10

多模态模型微调与评测口径建设 | Qwen3.5-9B · LoRA SFT · 冻结枚举评测 · 同基座对照

- 目标：在公开BIN图上分别评价类别与描述，为质检沟通提供可核对的模型结果。
- 参与动作：基于公开数据集 WM811K 的 5904 张抽样子集（固定种子 3407；train/val/test = 4721/594/589，跨划分 lot 交集为 0），按类别分层抽 3072 张训练池；在同一基座 Qwen3.5-9B 上 LoRA 微调两个同输入、同题面、只改监督答案的模型：L 只监督类别标签，D 监督类别 + 形态 + 中文描述。
- 评测口径（关键工作）：把「描述是否与图相符」的评法从自由文本正则改为冻结枚举 schema：六维枚举（SUPPORTED / PARTIAL / CONTRADICTED / UNCERTAIN / MISSING / NEEDS_REVIEW），并把「方向」拆成 applicable 与 verdict 两列；改口径后先跑 20/20 回归才开工。
- 对照设计：固定 36 图开发集，同题对照 8 个模型——本项目 L/D、原生基座、四个商用 API 模型与外部 GLM；冻结题面 sha256、固定解码参数，日志留痕可复算。
- 留出候选补测：另用 56 张与训练池 ID / lot / PNG 内容交集均为 0 的图，在同基座、同题面、同解码参数下补测 Base / L / D，并做同图配对差与 10000 次按图 bootstrap（seed 3407）；复核时把「视觉四维」与「格式」分列，不合成单一描述准确率。
- 实测结果（56 张留出候选：与训练池的 ID / lot / PNG 内容交集均为 0）：同基座只把监督从「无」换成类别标签，全 schema 门控类别准确率 0.2679 → 0.8214（同图配对 bootstrap 区间 [0.411, 0.696]，不含 0）；描述监督的 D 为 0.7679，与 L 之差 [-0.054, +0.161] 跨 0——本轮分不出高下。开发集 36 图上同基座对照 0.1667 → 0.8889，84 张开发验证集 77/84（91.7%）。本 56 图三模型严格 JSON 均 56/56 可解析；JSON 解析、完整 schema 与类别内容分别统计。
- 负结果与口径：36 图的 AI 描述复核不支持本项目超过最强外部模型；56 图的 L 与 D 配对区间跨 0。L 的 51/56 条 clock 字符串 null 是约定警告，完整 schema 不合法仅 1 条。该条类别答对，故类别字段独立口径 47/56、全 schema 门控 46/56。公开标签与 AI 的疑似分歧留档，未认定标签错误。
- 个人边界：公开数据研究，未使用内部数据、未做人审或产线部署。36 图是开发集，含 1 张与训练 PNG 相同的内容（另列 35 图诊断）；56 图是七类留出候选，完整历史接触未核，缺 Near_full/none。外部模型零样本，训练预算不同，保留比较局限。

推理服务化与可审计交付 | HTTP 服务 · Schema 校验 · 审计留痕 · 性能实测 · 预算守卫

- 目标：让推理结果可审计、可消费，保留原答及不确定/人工复核提示。
- 参与动作：把微调模型落成真实 HTTP 推理服务，设三条硬约束：输入合法性校验、JSON schema 校验、原答逐字节保留。关键取舍为 schema 不合不修补：坏结构一律标 needs_review 并留原答，只把「服务改过什么」单列成 format_changes 审计项。
- 工程化：对照侧设 20 元硬预算守卫（在途按 max_tokens 预留、完成按实际 usage 结算），并写死「每图一次请求、客户端重试 0、失败原件保留、不重新调用」，避免重试带来的选择偏差。
- 实测结果：租用单卡顺序完成 Base / L / D × 56 图 = 168 条真实推理，0 失败，单卡占用 541 秒（9.02 设备分钟），峰值显存约 19.1 GiB，释放后 1 MiB、无残留进程；每条先写 started 台账、再存原答与四项哈希（图片 / 题面 / 检查器 / adapter）。固定 36 图真实 HTTP 回放——36/36 返回 200，类别判对 25/36（固定 9 类 Macro-F1 0.6756），needs_review 19 条；时延 p50 ≈ 4.2 s、p95 ≈ 4.9–5.4 s；峰值已分配显存 17.88 GiB；CPU 工程契约测试 6/6 通过。API 对照 4 模型 × 36 图共 144 次尝试（132 正常返回 + 12 连接层失败），按标准价用量估算约 4.90 元 / 20 元上限（不是平台实付，失败未重发）。
- 限度：HTTP 成功不等于内容正确；时延含本客户端流程，12 次连接失败未重发，缺生产吞吐和稳定性证据。
- 个人边界：服务只跑在已获准的租用实例上做真实回放，未公网发布、未产线试点，故无 QPS 与线上稳定性数据；GPU 计费分钟与租机人民币实耗仓库内无账单可核，不代填。

协作边界说明（请勿删除）

- 本项目由多角色协作流程执行，项目文档记录的是角色分工而非个人分工；本人具体承担范围【待补】，故本页全部表述取最保守下界「参与」，不使用「主导 / 负责人 / Owner」。
- 数据/评测/对照的原始记录、哈希与口径说明随交付保留，本页数字可回溯到证据账本，并区分「模型自查」与「人工 gold」（后者本轮未做，永久留空）。

技能（本项目实际用到）

模型与训练：Qwen3.5-9B · LoRA / SFT（ms-swift） · 多模态输入构造

评测方法：冻结枚举 schema 设计 · 同基座对照 · 留出集隔离（ID / lot / 图像内容三重交集为 0） · 同图配对差与按图 bootstrap · Macro-F1 · 解析口径分层（严格 / 围栏诊断）

工程与交付：Python · HTTP 推理服务 · Schema 校验 · 原答逐字节留存与变更审计 · SHA-256 哈希链核对 · 预算守卫

数据：WM811K 抽样与分层 · lot 级隔离 · 图片内容级去重 · 留出候选考卷冻结（题面 / 检查器 / 逐图 SHA 冻结与上传前核对） · 候选质量分账