

项目经历

姓名：【待补】 | 联系方式：【待补】 | 目标岗位：【待补】 | 本页仅含项目经历

项目经历

晶圆 BIN 图缺陷判读与中文描述 · 视觉语言模型（公开数据个人项目） 2026.09 - 2026.10

多模态模型微调与评测口径建设 | Qwen3.5-9B · LoRA SFT · 冻结枚举评测 · 同基座对照

- 背景与目标：晶圆 BIN 图（格状缺陷热力图）判读核心是「格局属哪一类」，而质检沟通还需一句人能读的中文描述。目标：把「类别能力」与「描述能力」分开建模与评测，回答「该不该给描述监督」的工程取舍。
- 参与动作：基于公开数据集 WM811K 的 5904 张抽样子集（固定种子 3407；train/val/test = 4721/594/589，跨划分 lot 交集为 0），按公开类别分层抽出 3072 张训练池；在同一基座 Qwen3.5-9B 上 LoRA 微调两个同输入、同题面、只改监督答案的模型：L 只监督类别标签，D 监督类别 + 形态 + 中文描述。
- 评测口径（关键工作）：把「描述是否与图相符」的评法从自由文本正则改为冻结枚举 schema —— 六维四值（SUPPORTED / PARTIAL / CONTRADICTED / UNCERTAIN / MISSING / NEEDS_REVIEW），并把「方向」拆成 applicable 与 verdict 两列；改口径后先跑 20/20 回归才开工。
- 对照设计：固定 36 图开发集，问题对照 8 个模型 —— 本项目 L/D、原生基座、四个商用 API 模型与外部 GLM；冻结题面 sha256、固定解码参数，日志留痕可复算。
- 实测结果：同基座只把监督从「无」换成类别标签，准确率 0.1667 → 0.8889；84 张开发验证集上 77/84（91.7%），九类 Macro-F1 0.9227。基座原生输出带 Markdown 围栏，严格 JSON 判分几乎全失败 —— 必须把「格式失败」与「内容错误」分开计。
- 负结果（同批同图实测，一并报告）：（1）加了描述监督，类别准确率反而下降（0.8889 → 0.6944）；（2）本项目的描述并不优于外部零样本大模型 —— 视觉四维「好/坏」为 qwen3.8-max 113/3、GLM 105/10，优于 L 89/12、D 85/19；（3）L 六维合计垫底完全由「格式」一维造成，去掉格式后其视觉四维反好于 D，准确说法是「视觉内容中上、格式合规最差」。
- 个人边界：数据全部来自公开数据集，未使用公司内部数据、未做产线部署；描述结论是模型自查，不是人工金标；36 图是开发集而非盲测卷；本项目模型见过领域标签、外部模型为零样本，分数差不是训练预算对齐的因果对比。

推理服务化与可审计交付 | HTTP 服务 · Schema 校验 · 审计留痕 · 性能实测 · 预算守卫

- 背景与目标：工业质检里模型输出的可审计性与准确率同等重要 —— 需知道「结果是模型原样给的、还是服务改过的」，也需明确的「不确定、请人工看」标记。
- 参与动作：把微调模型落成真实 HTTP 推理服务，设三条硬约束：输入合法性校验、JSON schema 校验、原答逐字节保留。关键取舍为 schema 不合不修补：坏结构一律标 needs_review 并留原答，只把「服务改过什么」单列成 format_changes 审计项。
- 工程化：对照侧设 20 元硬预算守卫（在途按 max_tokens 预留、完成按实际 usage 结算），并写死「每图一次请求、客户端重试 0、失败原件保留、不重新调用」，避免重试带来的选择偏差。
- 实测结果：固定 36 图真实 HTTP 回放 —— 36/36 返回 200，类别判对 25/36（固定 9 类 Macro-F1 0.6756），needs_review 19 条；时延 p50 ≈ 4.2 s、p95 ≈ 4.9–5.4 s；峰值显存 17.88 GiB；CPU 工程契约测试 6/6 通过。API 对照 4 模型 × 36 图共 144 请求，实付约 4.90 元 / 20 元上限（132 成功 + 12 连接层失败，失败未重发）。
- 不达标项（照实写）：「HTTP 通过」≠「内容正确」—— 36/36 返回 200，但只有 25/36 判对；时延是同客户端端到端，不是外部网络时延；12 条连接层失败为遵守「不做二次调用」纪律而未补齐。
- 个人边界：服务只跑在已获准的租用实例上做真实回放，未公网发布、未产线试点，故无 QPS 与线上稳定性数据；GPU 计费分钟与租机人民币实耗仓库内无账单可核，不代填。

协作边界说明（请勿删除）

- 本项目由多角色协作流程执行，项目文档记录的是角色分工而非个人分工；本人具体承担范围【待补】，故本页全部表述取最保守下界「参与」，不使用「主导 / 负责人 / Owner」。
- 数据/评测/对照的原始记录、哈希与口径说明随交付保留，本页数字可回溯到证据账本，并区分「模型自查」与「人工 gold」（后者本轮未做，永久留空）。

技能（本项目实际用到）

模型与训练：Qwen3.5-9B · LoRA / SFT (ms-swift) · 多模态输入构造
评测方法：冻结枚举 schema 设计 · 同基座对照 · Macro-F1 · 置信区间 · 解析口径分层（严格 / 围栏诊断）
工程与交付：Python · HTTP 推理服务 · Schema 校验 · 原答逐字节保留与变更审计 · SHA-256 哈希链核对 · 预算守卫
数据：WM811K 抽样与分层 · lot 级隔离 · 图片内容级去重 · 候选质量分账